Recuperarea datelor (cont)

Recuperarea distribuită

- Tipuri noi de eşec: întrerupere rețea şi oprire *site*-uri
- Dacă "sub-tranzacțiile" unei tranzacții sunt executate pe *site*-uri diferite, trebuie să ne asigurăm că se vor comite toate sau nici una.

- E nevoie de un protocol de comitere a "sub-tranzacțiilor" unei tranzacții
  - Fiecare site are propriul log unde se vor memora acțiunile protocolului de comitere.

Problema generalilor bizantini

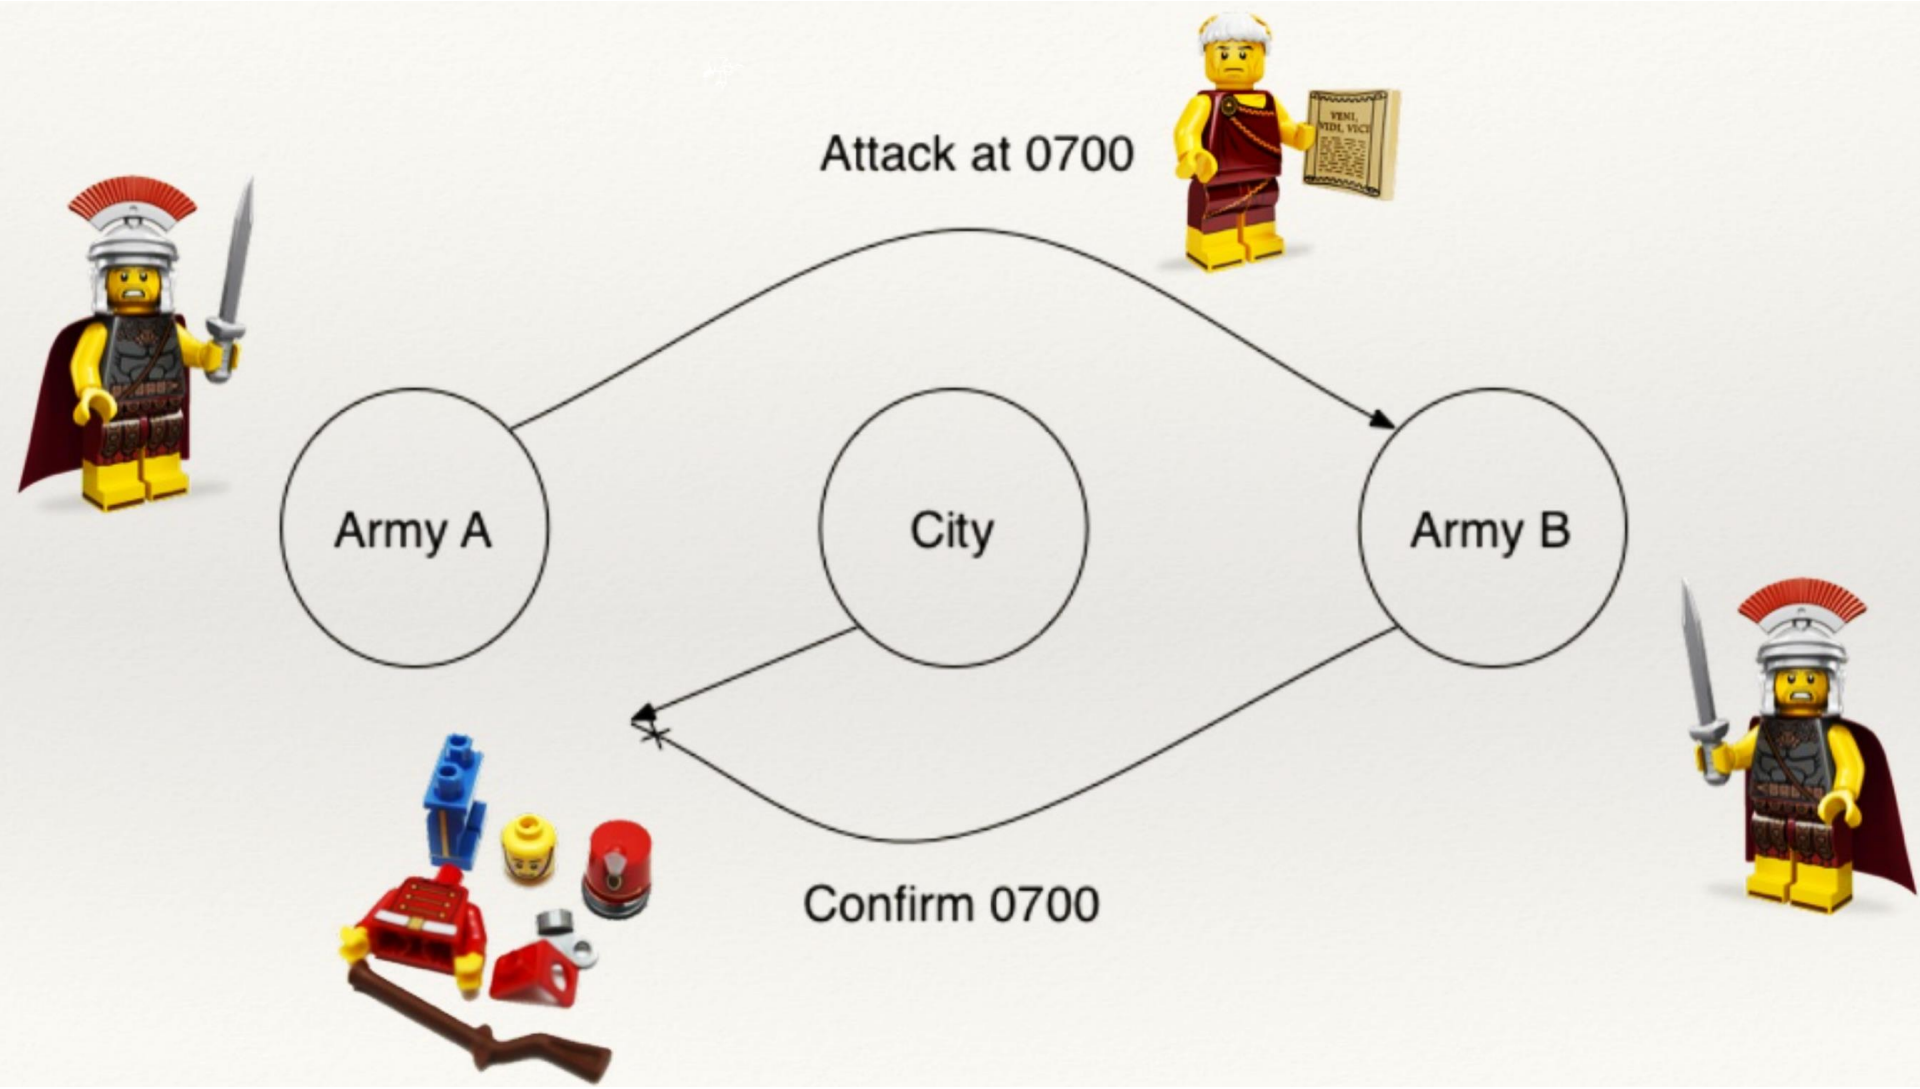

Problema generalilor bizantini

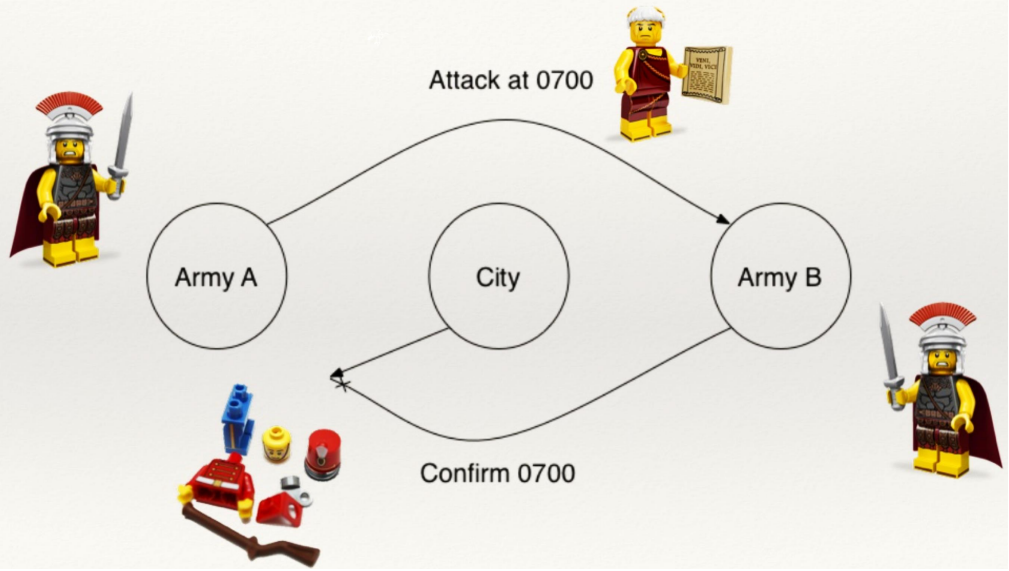

- Un oraș se află sub asediul a două armate aliate
- Fiecare armată are un general (unul dintre ei e liderul)
- Armatele trebuie să agreeze dacă atacă sau nu
- Comunică prin transmitere de mesaje
- Mesagerul poate fi capturat

Comitere în două faze (2PC)

- *Site*-ul de unde se generează tranzacția se numeşte coordonator; celelalte *site*-uri pe care se execută se numesc subordonate.
- Atunci când tranzacția comite:
  1. Coordonatorul transmite mesajul **prepare** tuturor subordonaților.
  2. Subordonații inserează **abort** sau **prepare** în log şi apoi transmit mesajul **no** sau **yes** către coordonator.
  3. Dacă coordonatorul primeşte *yes* de la toți subordonații, inserează **commit** în log record şi transmite **commit** tuturor. Altfel, inserează **abort** în log rec şi transmite **abort** tuturor.
  4. Subordonații inserează **abort/commit** în log pe baza mesajului primit, apoi transmit **done** coordonatorului.
  5. Coordonatorul scrie **end** în log după ce primeşte toate *done*-urile.

Comitere în două faze (2PC)

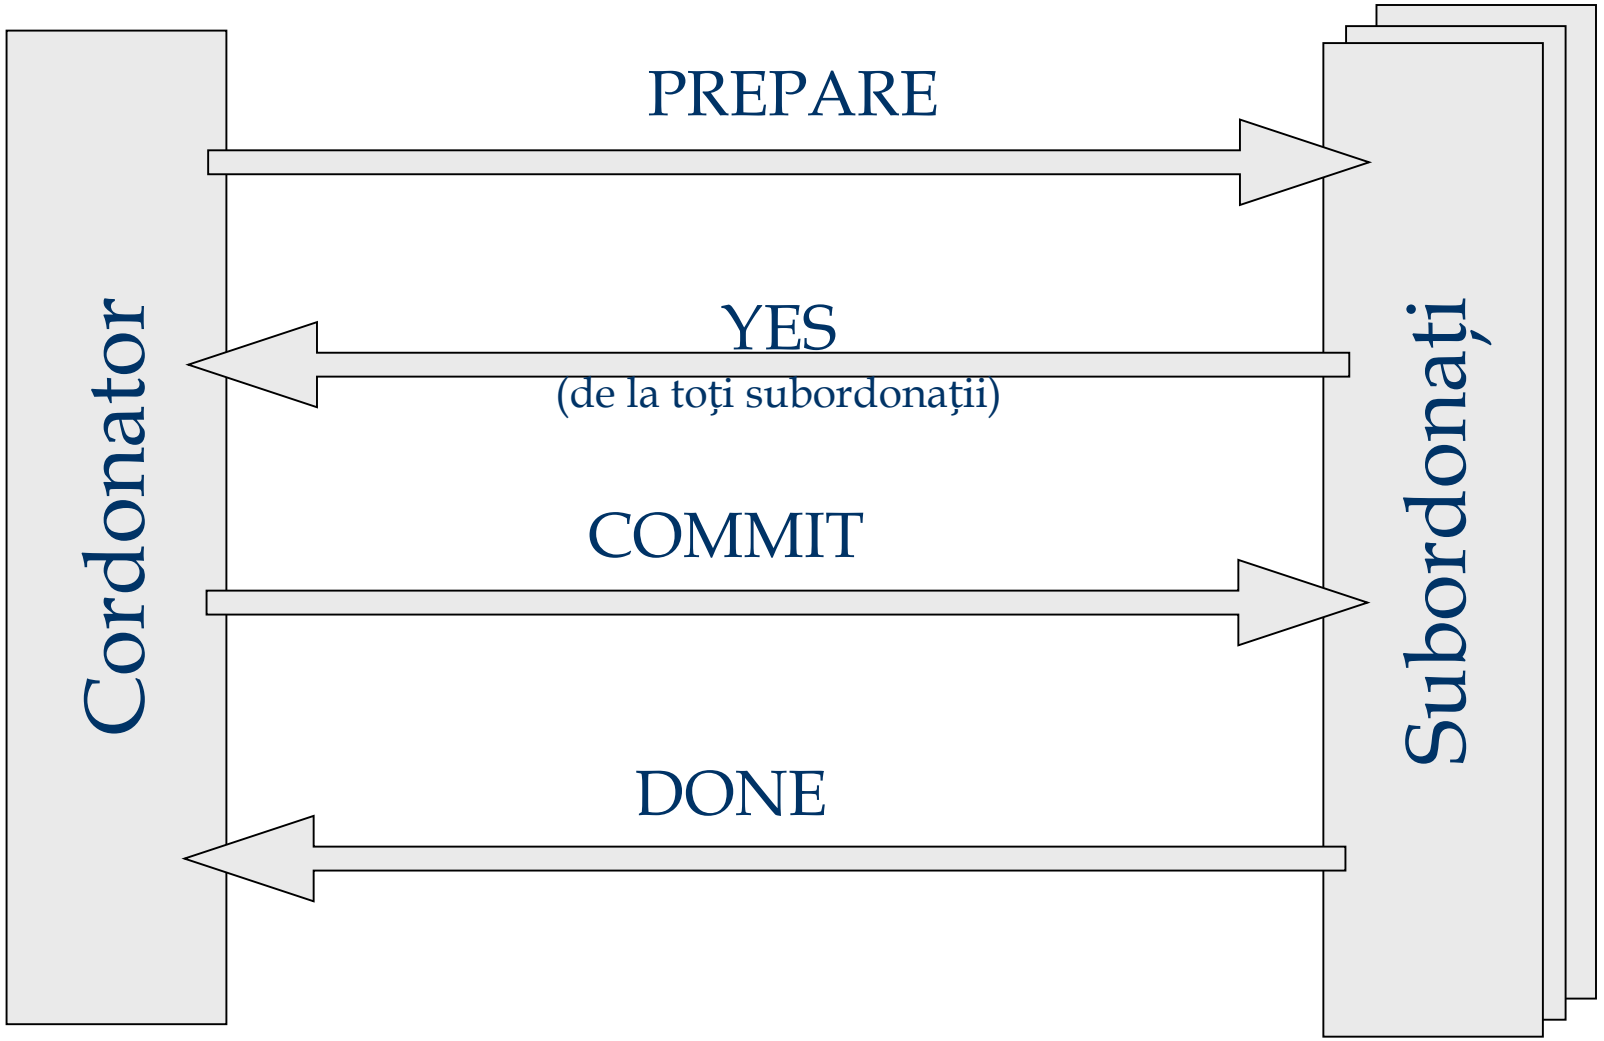

Comitere în două faze (2PC)

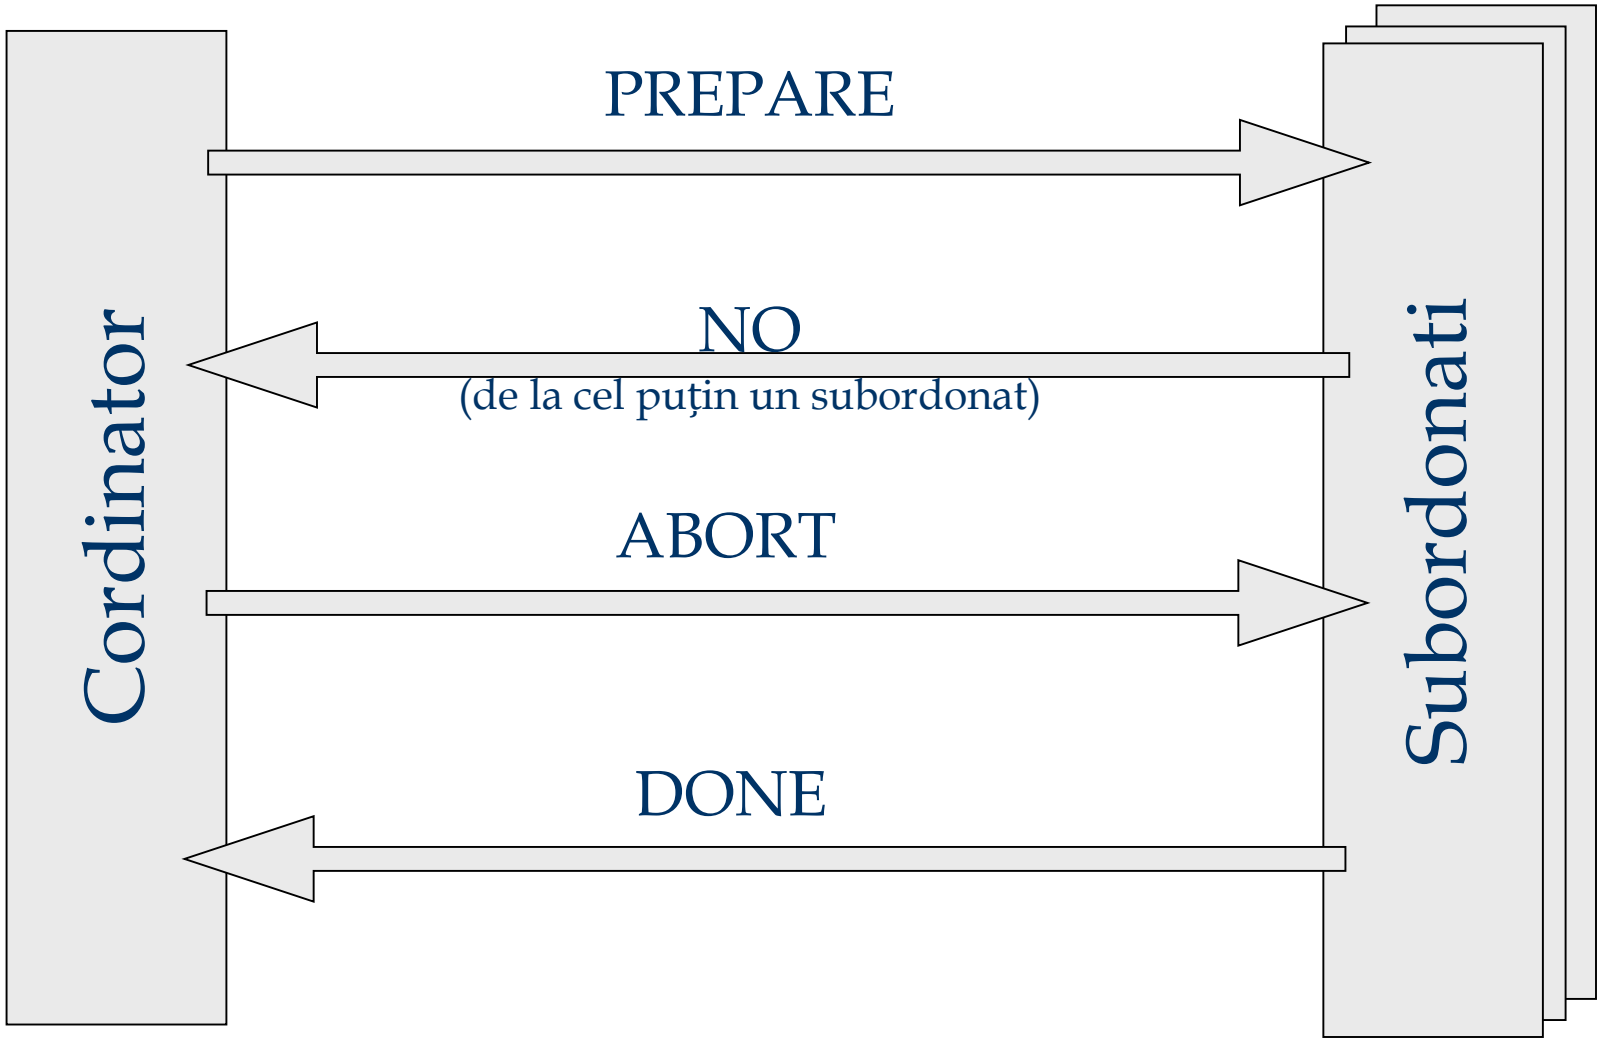

Comentarii asupra 2PC

- Două runde de comunicare: votare urmat de terminare. Ambele sunt inițiate de coordonator.
- Orice site poate decide eşuarea tranzacției.
- Fiecare mesaj reflectă o decizie; pentru a garanta că această decizie rezistă unor erori, ea este inserată mai intâi într-un log .
- Toate intrările în log conțin *TransactionID* şi *CoordinatorID*. Comenzile abort/commit logate de către coordonator includ id-urile tuturor subordonaților.

2PC – Recuperarea datelor

- Dacă avem un commit sau abort logat pentru tranzacția T, dar nu este un end, se apelează *redo*/*undo* pentru T.
  - Dacă site-ul este coordonator pentru T, se vor transmite mesaje **commit/abort** către subordonați până se recepționează **done**.

2PC – Recuperarea datelor

- Dacă avem un prepare logat pentru tranzacția T, dar nu este commit/abort, iar site-ul este subordonat lui T.
  - se contactează coordonatorul în mod repetat pentru verificarea stării lui T, apoi se inserează **commit/abort** în log rec + redo/undo aplicat asupra lui T; se inserează **end** în log.

2PC – Recuperarea datelor

- Dacă nu apare nici măcar un prepare în log pentru T, T se va termina unilaterar
  - Acest site poate fi chiar coordonator!

2PC - Blocări

- Când coordonatorul pentru tranzacția T eşuează , subordonații care au votat yes nu se vor putea decide dacă să se termine cu *commit* sau *abort* până când coordonatorul îşi revine.
  - T este blocat.
  - Chiar dacă toți subordonații ar putea comunica între ei (prin extra info transmisă cu mesajul prepare) ei rămân blocați până când unul din ei transmite no.

2PC - Eşuarea reţelei / a unui site

- Dacă un site nu răspunde în timpul derulării protocolului de comitere pentru tranzacţia T:
  - dacă site-ul curent este coordonator pentru T, T va trebui întrerupt.
  - dacă site-ul curent este un subordonat şi nu a transmis încă yes, T va trebui întrerupt.
  - dacă site-ul curent un subordonat şi a transmis yes, este blocat până când coordonatorul răspunde.

2PC - Observații

- Mesajul done e folosit pentru a informa coordonatorul că poate "ignora" o tranzacție; tranzacția T rămâne în tabela de tranzacții până aceasta recepționează toate mesajele done.
- Dacă coordonatorul eşuează după trimiterea mesajului prepare şi înainte de scrierea în log a intrucțiunilor commit/abort, la revenire tranzacția se va termina fără succes.
- Dacă o sub-tranzacție nu modifică BD, faptul că ea se comite sau nu este ***irelevant***.

2PC cu eşuare dedusă

- Atunci când coordonatorul întrerupe tranzacția T, reface contextul de dinaintea executiei lui T şi o elimină imediat din tabela de tranzacții.
  - Mesajele **done** nu se mai aşteaptă; avem "eşec dedus" dacă transacția nu se află în tabela de tranzacții. Intrarea **abort** din log nu conține în acest caz numele subordonaților.

2PC cu eşuare dedusă

- Subordinații nu transmit done la eşec
- Dacă sub-trazactiile nu modifică BD, acestea răspund la prepare cu reader in loc de yes/no.
- Coordonatorul va ignora tranzacțiile "*reader*".
- Dacă toate sub-transacțiile sunt "*reader*" a doua fază nu este necesară.

Protocol de comitere în trei faze (3PC)

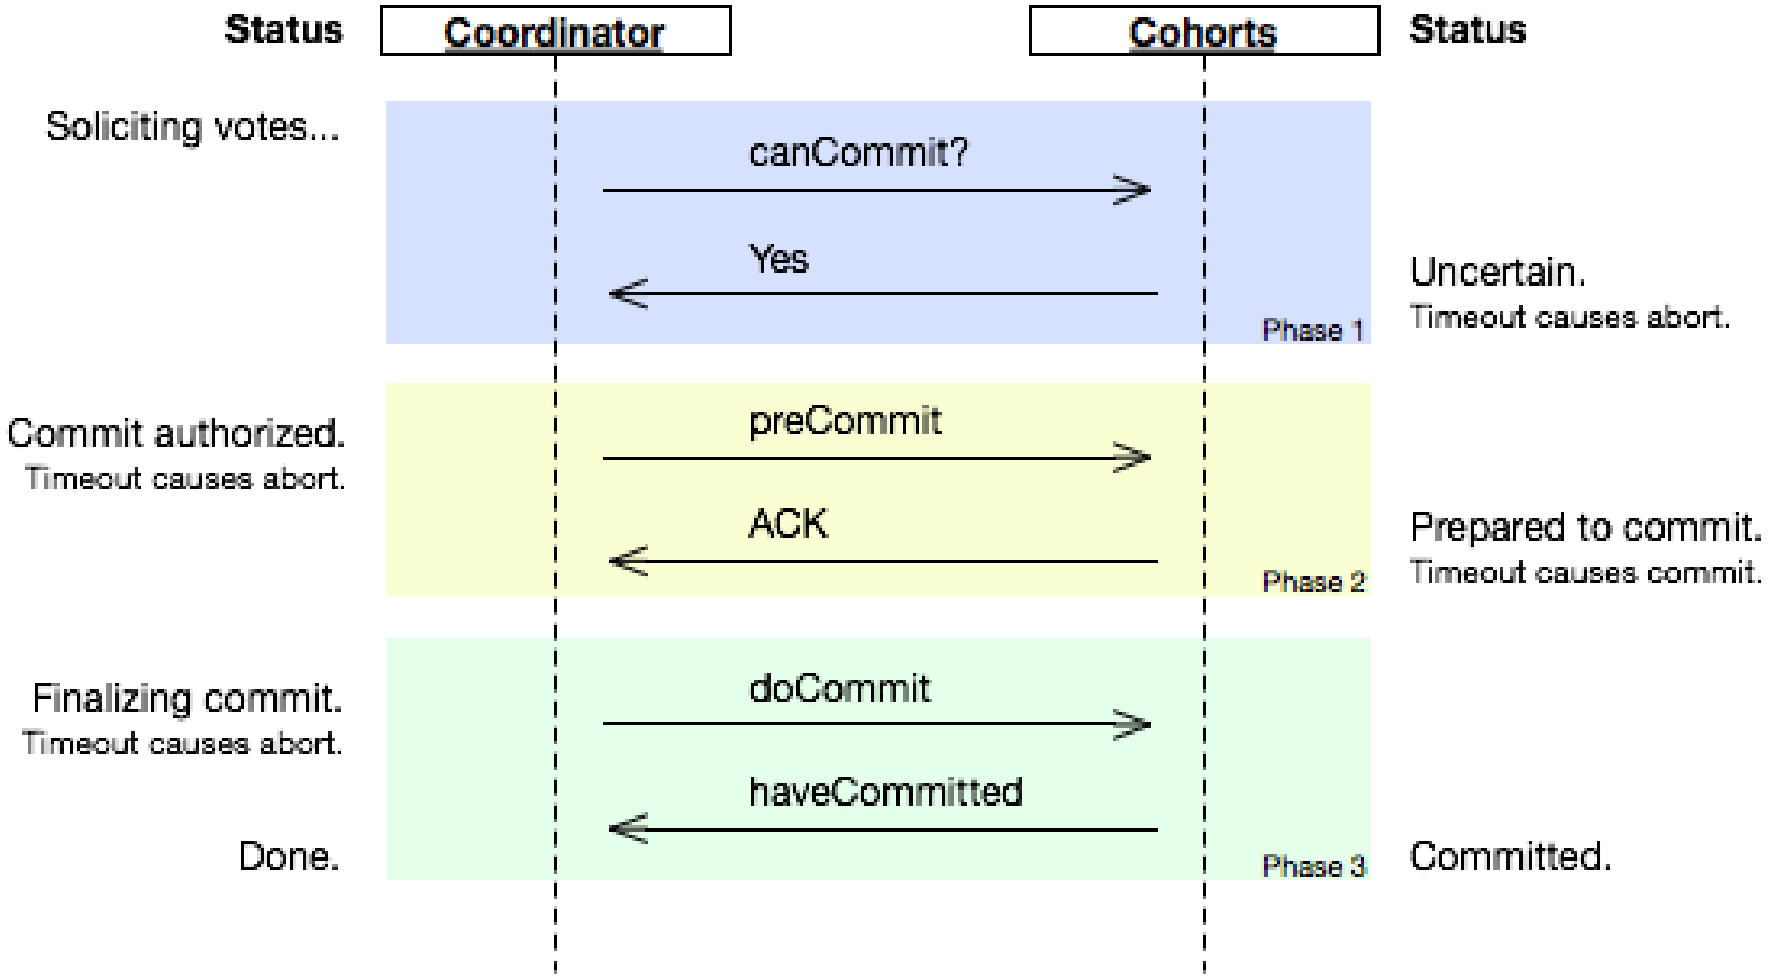

Recuperarea datelor într-un context nedistribuit

Actualizarea datelor

- **Actualizare imediată**: De îndată ce s-a realizat o modificare în *buffer*, este actualizat și corespondenta paginii de date de pe disc.
- **Actualizare amânată**: Toate datele modificate în *buffer* sunt actualizate pe disc după ce execuția unei tranzacții sau a unui număr fix de tranzacții este finalizată.
- **Actualizare *"in-place"*** : Versiunea originală a paginii ce conține datele pe disc este suprascrisă de corespondenta sa din *buffer*.
- **Actualizare *"shadow"***: Pagina de date din buffer nu se copiază peste corespondenta sa originală de pe disc, ci peste o copie a acesteia memorată la o adresă diferită.

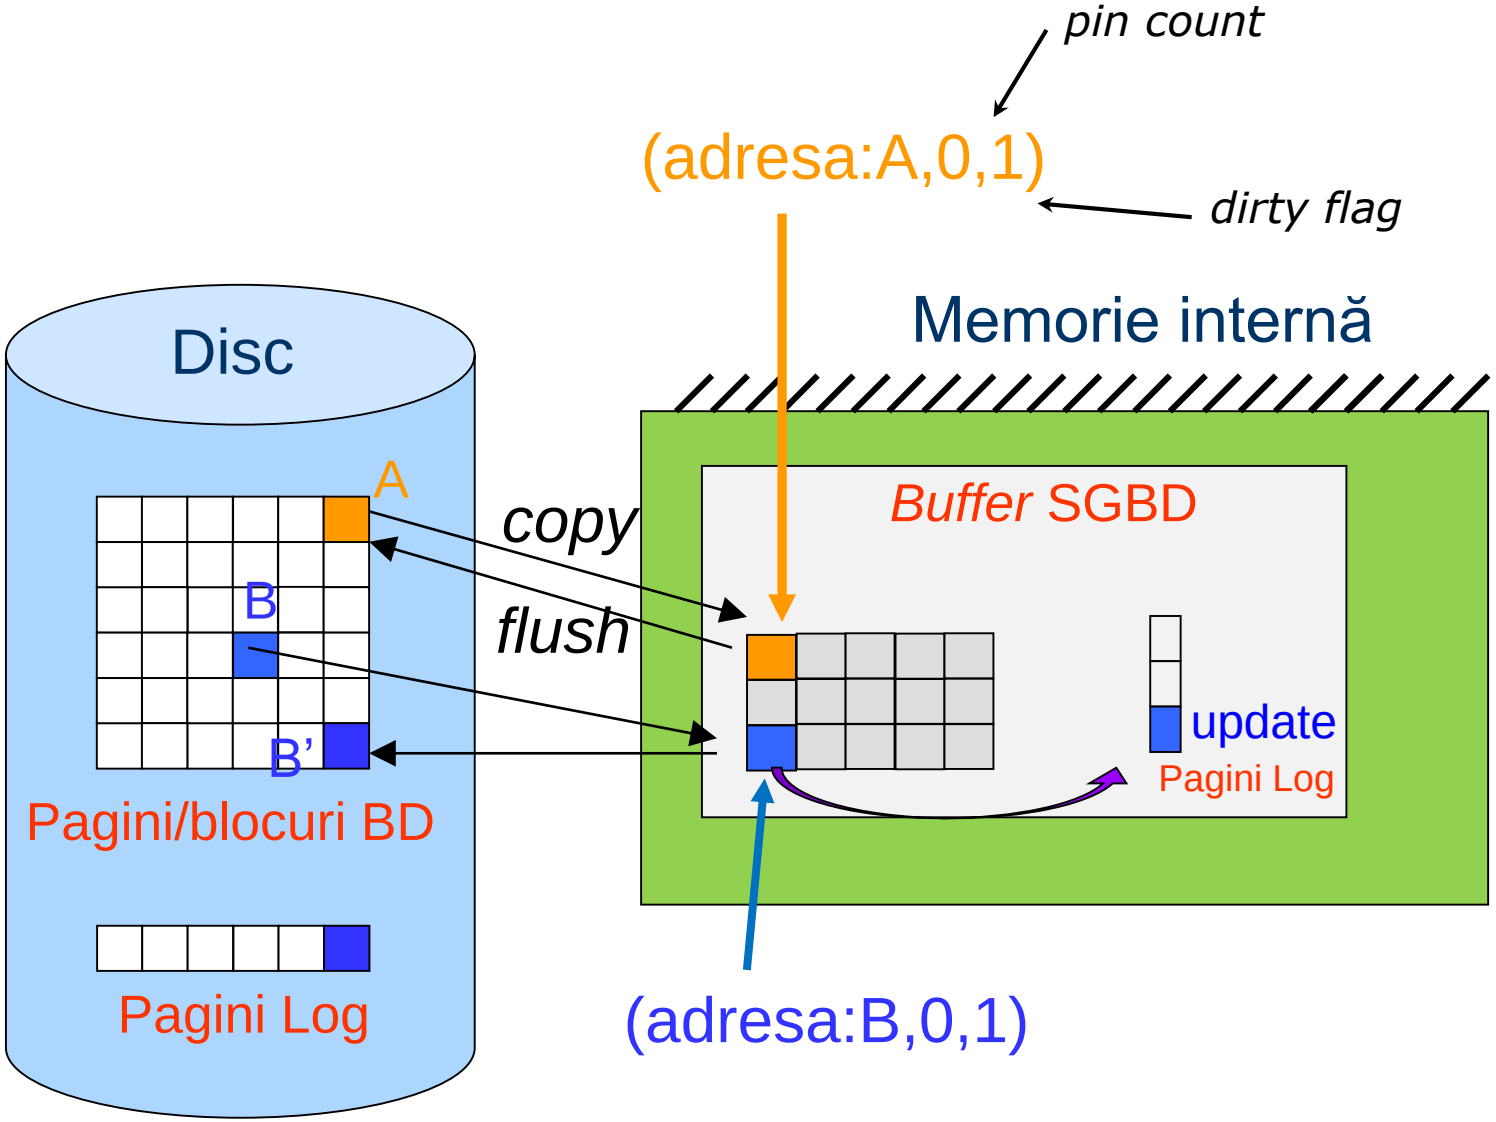
pin count
(adresa:A,0,1)
dirty flag
Memorie internă
Disc
A
B
B'
copy
flush
Buffer SGBD
update
Pagini Log
Pagini/blocuri BD
Pagini Log
(adresa:B,0,1)

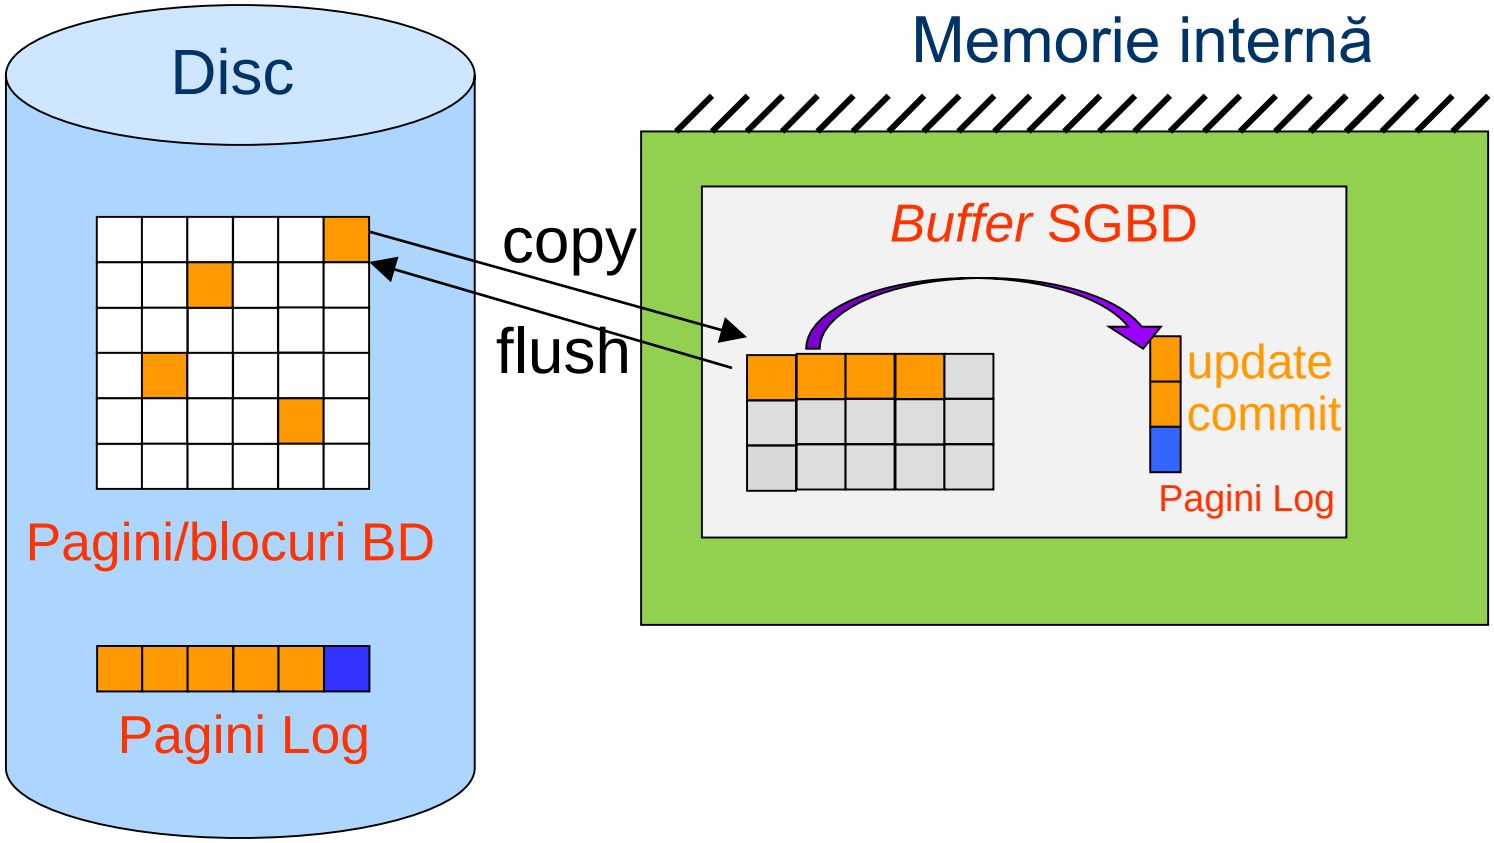

Protocol **Write-Ahead Logging** (WAL):

1. Trebuie asigurată adăugarea unei intrări coresp. unei modificări în log *înainte* ca pagina ce conţine înregistrarea sa fie salvată pe disc.
2. Trebuie adăugate toate intrările corespunzătoare unei tranzacţii înainte de *commit*.

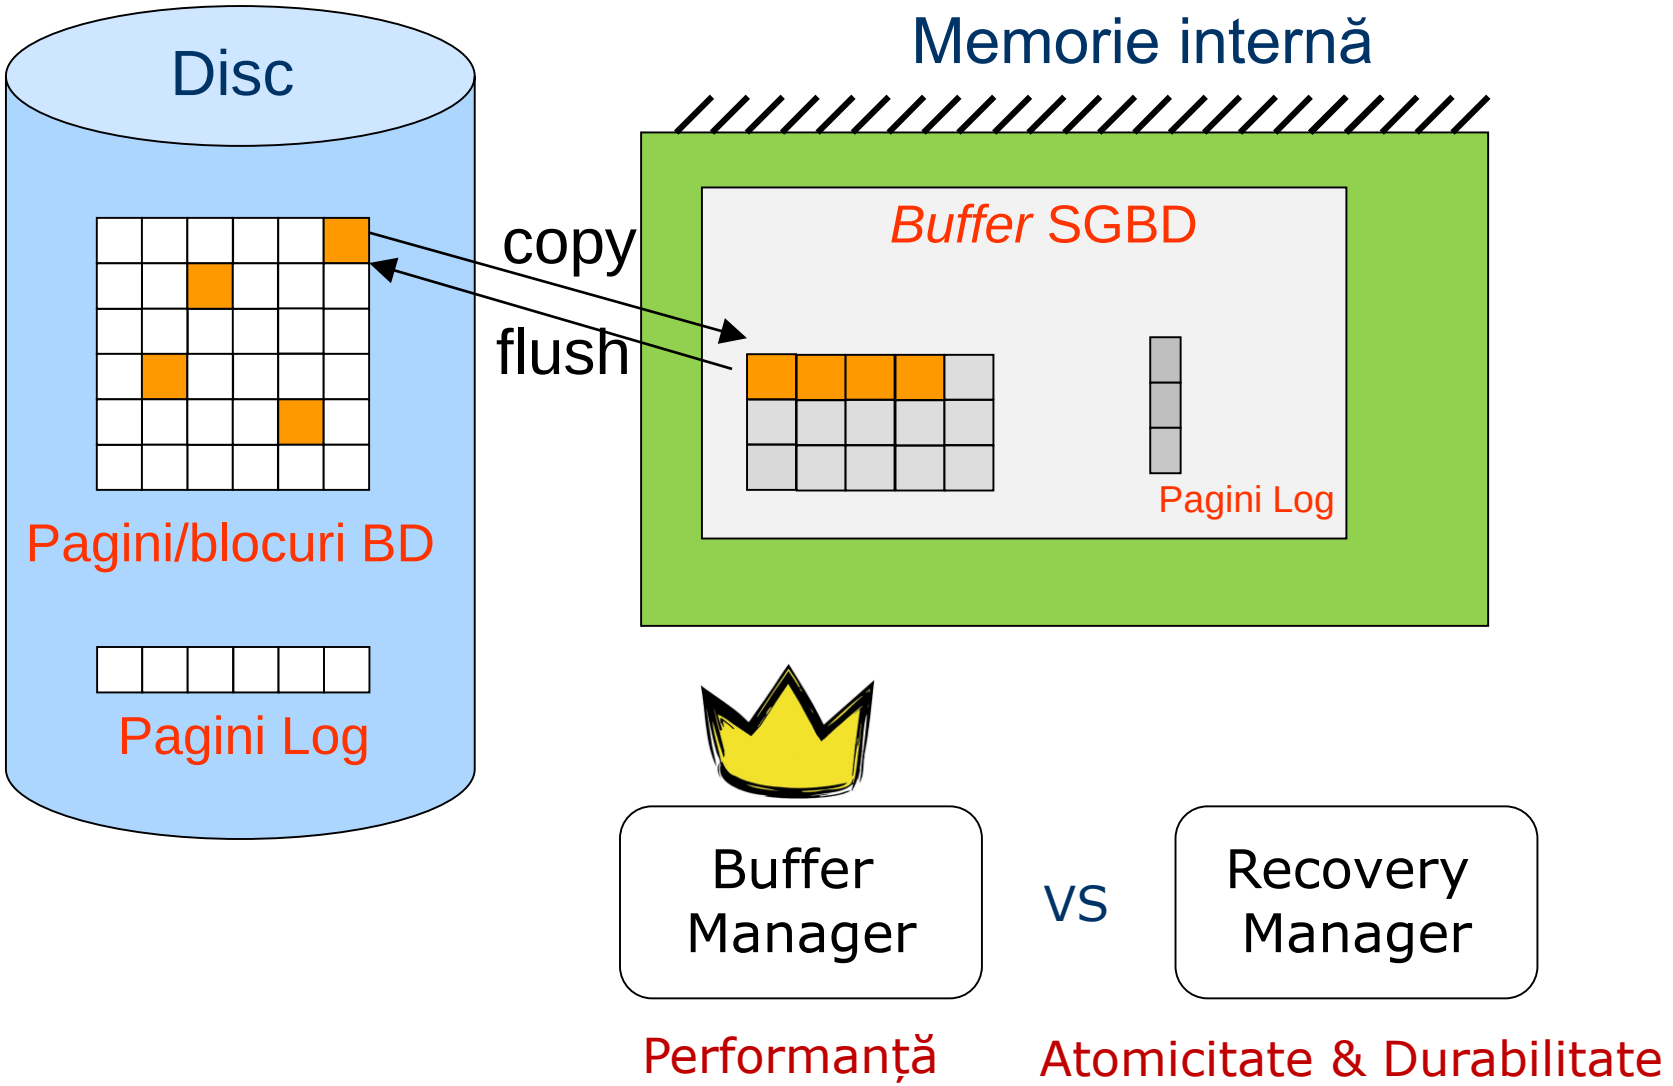
Disc
Memorie internă
Buffer SGBD
copy
flush
Pagini/blocuri BD
Pagini Log
Pagini Log
Buffer Manager
VS
Recovery Manager
Performanță
Atomicitate & Durabilitate

- Poate decide *Buffer Manager*-ul salvarea anumitor pagini (modificate de o tranzacție) din *buffer* pe disc fără a aştepta instrucțiuni specifice de la *Recovery Manager*?
  - Decizie ***steal / no-steal***
  - *No-steal* înseamnă că RM păstrează referința către paginile modificate din *buffer*

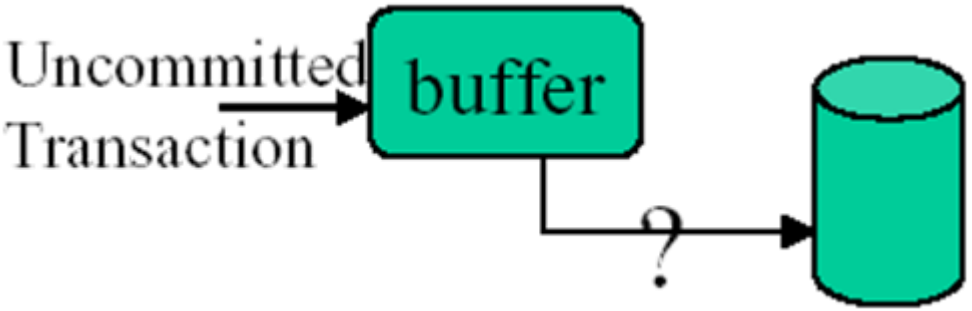

- Poate *Recovery Manager* "forța" *Buffer Manager* să salveze anumite pagini din *buffer* pe disc la finalul executării unei tranzacții?
  - Decizie ***force / no-force***

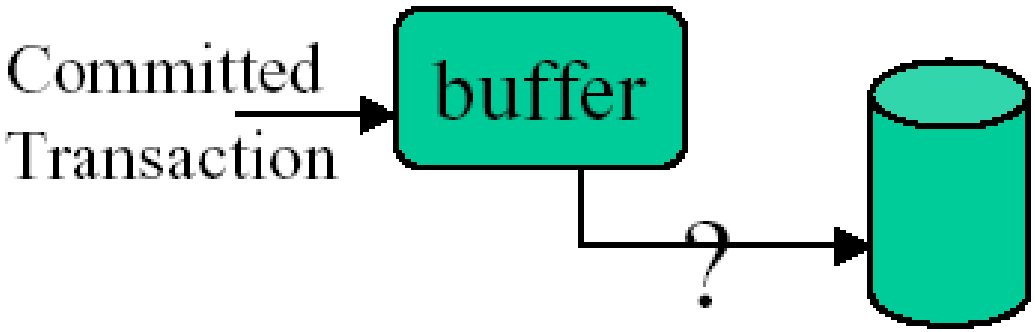

- Se forțează salvarea pe disc a fiecărei modificări?
  - Timpi mari de răspuns.
  - Garantează durabilitatea.

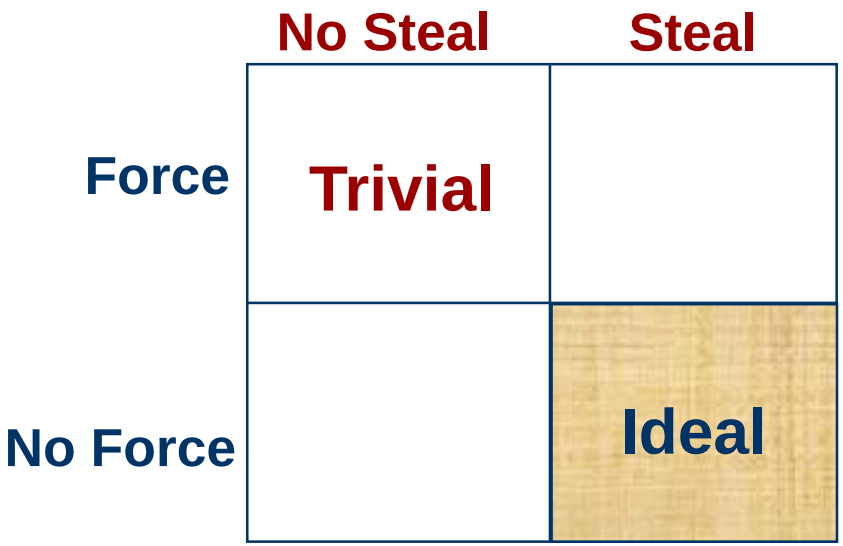

- Se permite salvarea unor pagini de memorie modificate de tranzacții ce nu s-au comis?
  - Dacă nu, concurență redusă, anumite tranzacții fiind blocate.
  - Dacă da, cum se poate garanta atomicitatea?

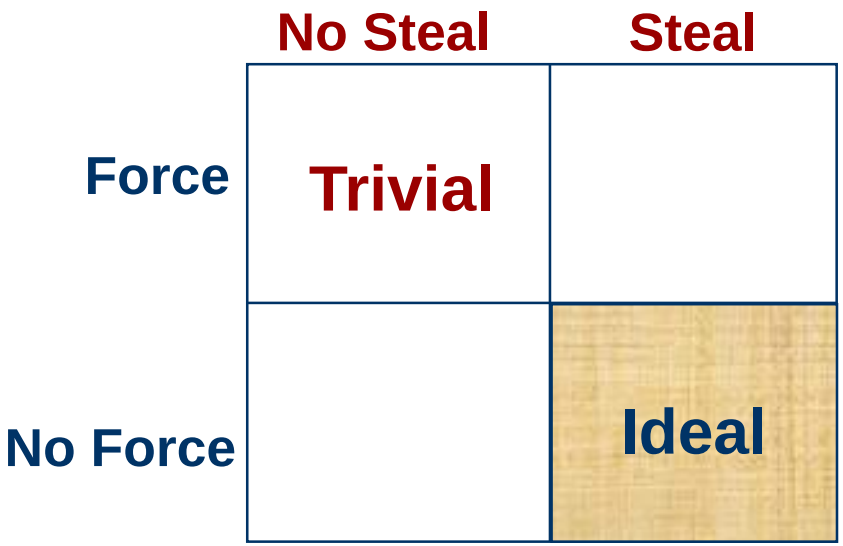

- **Steal / No-force**
  - BM poate salva modificări intermediare ale tranzacțiilor. RM salvează doar un *commit*
- Steal / force
  - BM poate salva modificări intermediare ale tranzacțiilor. RM salvează toate modificările (*flush)* înainte de *commit*
- No-steal / no-force
  - Nici una din paginile modificate nu se salvează decât la *commit*. RM salvează un *commit* şi elimină referințele către paginile modificate.
- No-steal / force
  - Nici una din paginile modificate nu se salvează decât la *commit*. RM salvează toate modificările (*flush)* la *commit*

- **STEAL** (de ce garantarea *Atomicității* e dificilă)
  - *To steal frame F:* Pagina curentă memorată în F (să spunem P) este copiată pe disc; este posibil ca anumite tranzacții să blocheze anumite obiecte memorate în P.
    - Ce se întâmplă dacă tranzacția k, ce bloca anumite obiecte din P, eșuează?
    - Trebuie memorată vechea valoare a lui P (pentru a aplica UNDO modificărilor apărute în pagina P).

- **NO FORCE** (de ce garantarea *Durabilității* e dificilă)
  - Ce se întâmplă dacă sistemul se blochează înainte ca o pagină modificată să fie copiată pe disc?
  - În momentul comiterii unei tranzacții este necesar să se scrie pe disc informația minimă pentru ca modificările tranzacției să poată fi reproduse.

Contextul WAL

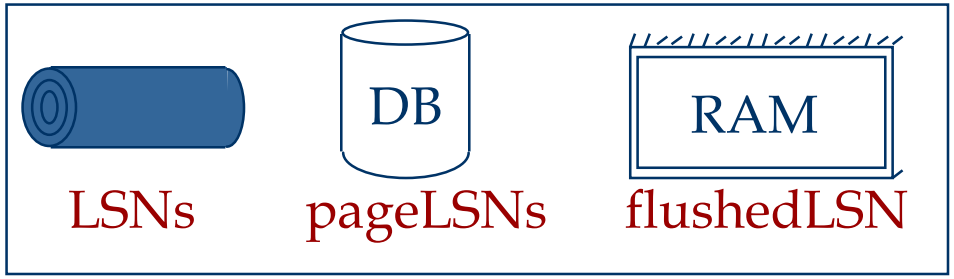

- Fiecare intrare din log are un Log Sequence Number (LSN).
  - LSN creşte incremental.

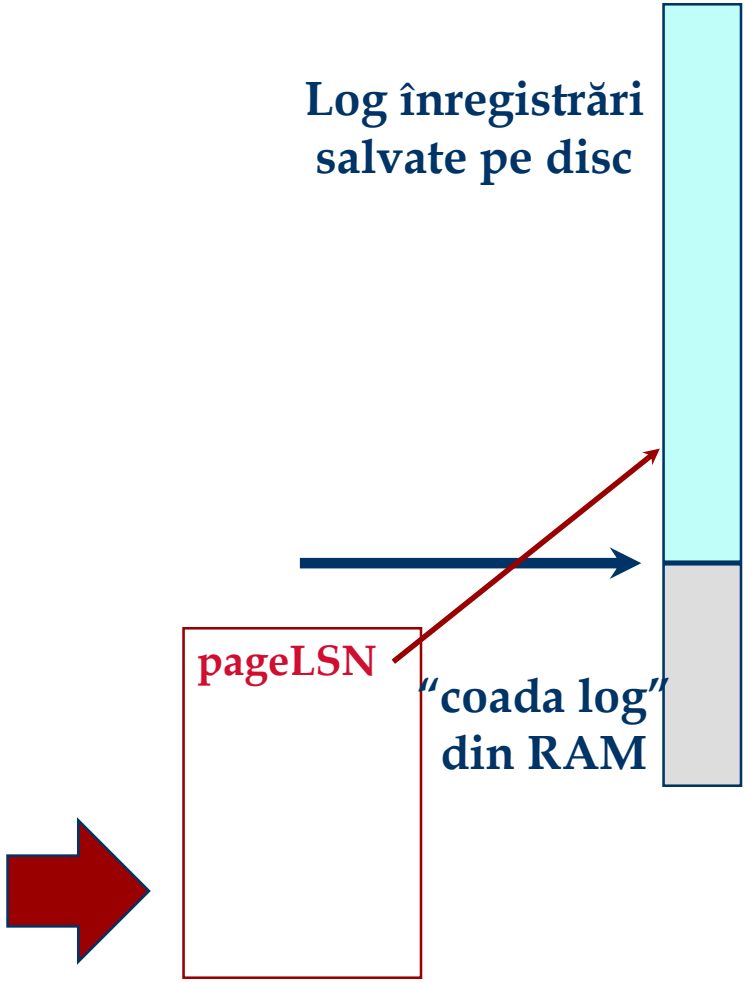

Contextul WAL

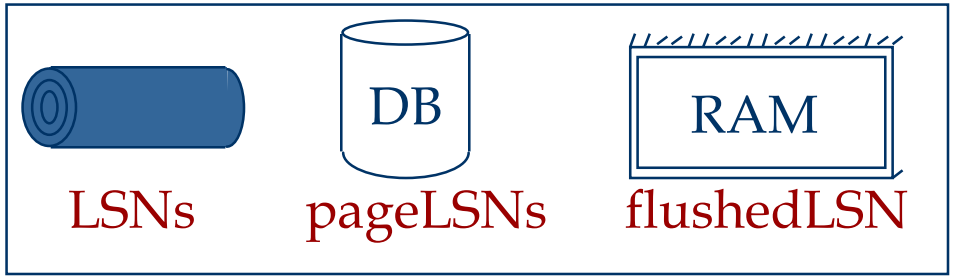

- Fiecare *pagină de date* conține un pageLSN.
  = LSN al celei mai recente *intrări din log*
  a unei modificări din pagină.

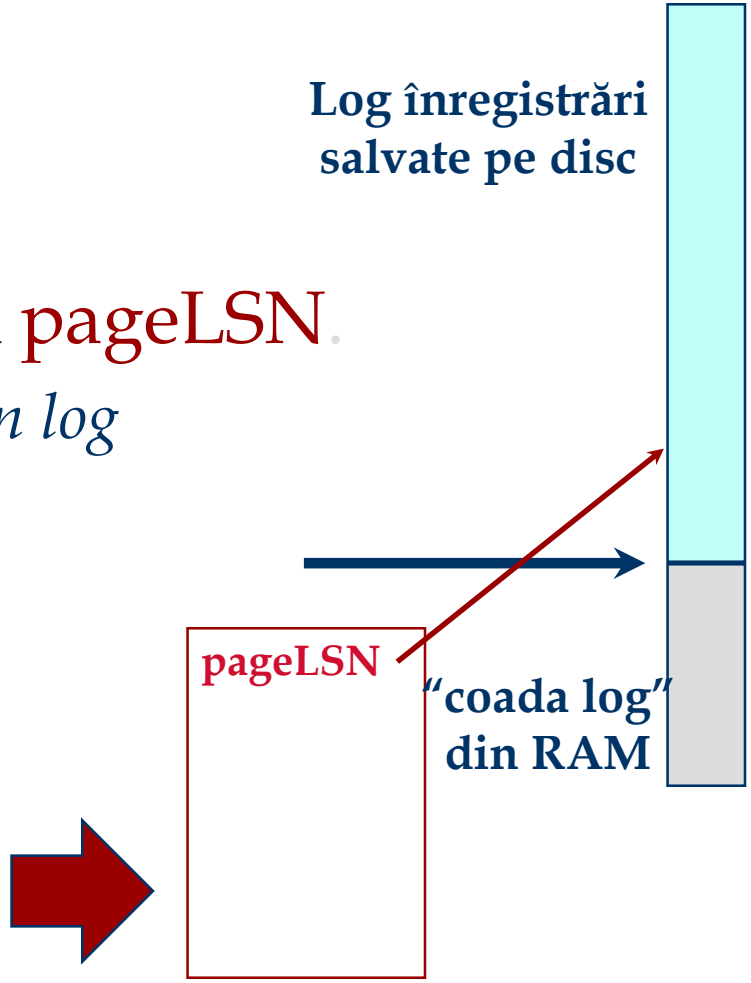

Contextul WAL

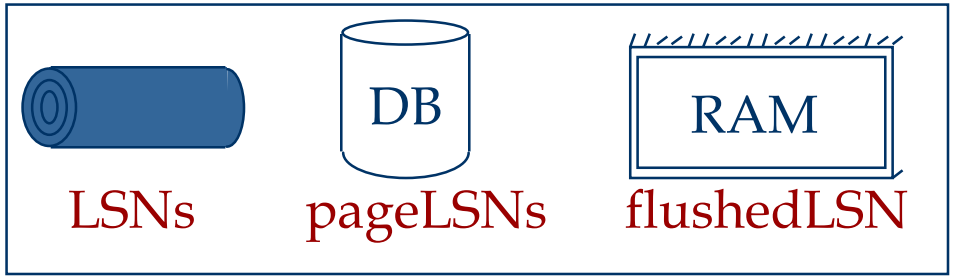

- Sistemul mai reține flushedLSN.
  - LSN maxim până la care totul e salvat pe disc.

- WAL:
  - pageLSN ≤ flushedLSN

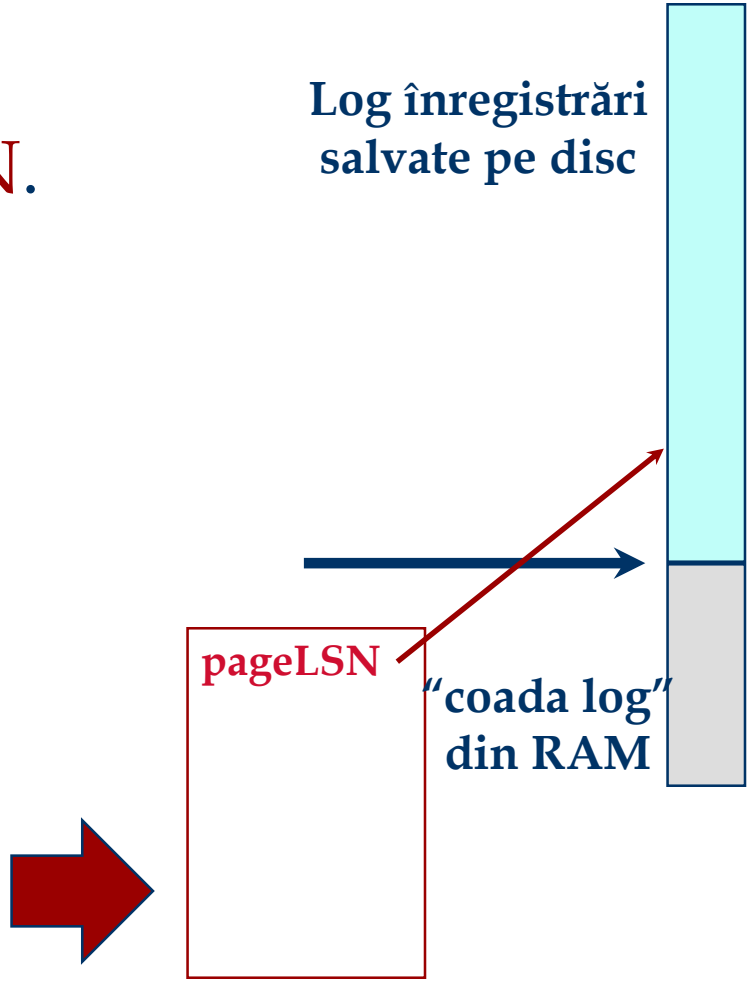

Intrări ale *log*-ului

Câmpurile intrărilor :

LSN
prevLSN
TransID
type

Doar pentru **modificări**:
- pageID
- length
- offset
- before-image
- after-image

Tipuri posibile de intrări:

- **Update**
- **Commit**
- **Abort**
- **Checkpoint**
- **End** (semnifică terminarea unui *commit* sau *abort*)
- Compensation Log Records (CLRs)

  – pentru UNDO

Compensation Log Record (CLR)

- Utilizat în faza de recuperare a datelor
- Este adăugat chiar înainte de anularea unei modificări marcate printr-o intrare în log
- Conține un câmp numit undoNextLSN
  - LSN-ul următoarei intrări de tip *update* ce trebuie anulată pentru o anumită tranzacție
  - Se inițializează cu *prevLSN* al intrării curente
- Indică ce acțiuni au fost deja anulate
- Previne anularea de mai multe ori a aceleiaşi acțiuni

Alte construcții utilizate de RM

- Tabela de tranzacții:
  - O înregistrare pentru fiecare tranzacție activă.
  - Conține XID (id tranzacție), stare (running / committed / aborted) şi lastLSN.

- Tabela paginilor cu modificări (*Dirty Page Table*):
  - O înregistrare pentru fiecare pagină cu modificări din *buffer*.
  - Conține recLSN – LSN al ***primei*** intrări din log care a adus o modificare paginii.

Execuția normală a unei tranzacții

Context

- Secvență de citiri & modificări, urmate de commit sau abort
  - Vom presupune că scrierea unei pagini pe disc e atomică
- *Strict 2PL*.
- Abordare gestiune *buffer*: STEAL, NO-FORCE
- Write-Ahead Logging.

Vedere de ansamblu

Intrări Log

- prevLSN
- XID
- type
- pageID
- length
- offset
- before-image
- after-image

Pagini de date

fiecare
cu un
pageLSN

Master record

Tabelă tranzacţii

lastLSN
stare

Tabelă pagini modif.

recLSN

flushedLSN

Exemplu:
Întreruperea simplă a unei tranzacții

- Se consideră întreruperea explicită a unei tranzacții.
- Se parcurge log-ul în ordine inversă, anulând modificările.
  - Se porneşte de la lastLSN al tranzacției din tabela de tranzacții
  - Se parcurge lista de intrări ale log-ului urmând câmpul prevLSN
  - Înainte de anulare se adaugă o înregistrare *Abort* în log
    - utilă la recuperararea în cazul unei întruperi în timpul operației de anulare a modificărilor!

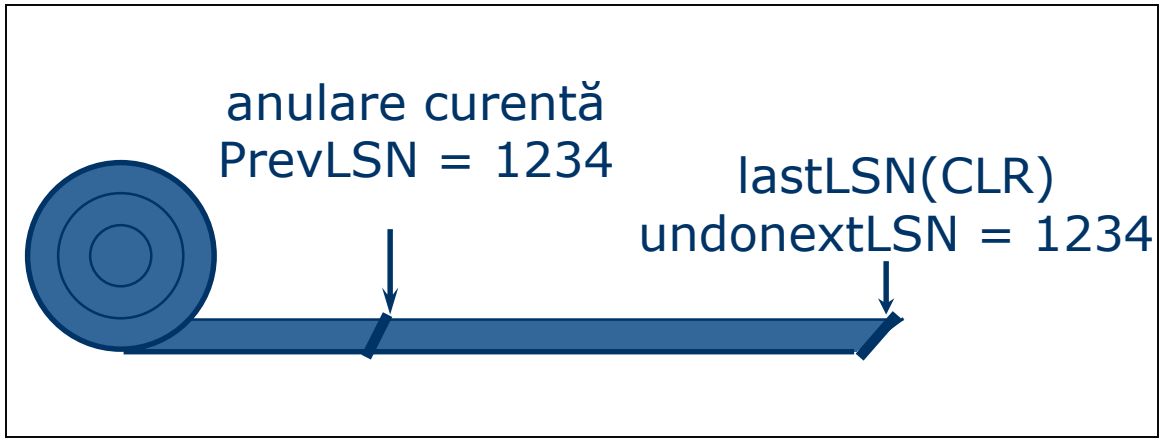

- Obiectul a căreia modificare se anulează va fi blocat!
- Înainte de salvarea noii valori se adaugă un CLR:
  - Log-ul se actualizează şi pe parcursul anulării!
  - Câmpul undonextLSN al CLR referă următoarea intrare din log pentru anulat (adică *prevLSN* al înregistrării anulate).
  - Intrările de tip CLR nu se anulează *niciodată*
- La finalul anulării tuturor modificărilor tranzacției se inserează o intrare end în log.

Comiterea unei tranzacții

- Se inserează o intrare commit în log.
- Toate intrările de log corespunzătoare tranzacției se salvează pe disc (până la lastLSN).
  - Garantează că flushedLSN ≥ lastLSN.
  - Inserările în log se fac secvențial, sincron pe disc
  - Există mai multe intrări de log per pagină.
- Se inserează o intrare end în log.

Faze ale ARIES

(*Algorithm for Recovery and Isolation Exploiting Semantics*)

- *Analiză*: Se parcurge *log*-ul de la cel mai recent *checkpoint* spre final pentru identificarea tuturor tranzacțiilor active şi a tuturor paginilor modificate existente în *buffer* la momentul întreruperii
- *Redo*: Reface toate modificările paginilor din *buffer,* corespunzătoare tranzacțiilor comise înainte de întrerupere, pentru a asigura că toate modificările s-au salvat pe disc.
- *Undo*: Modificările tuturor tranzacțiilor active în momentul întreruperii se anulează (folosing *valoarea anterioară* prezentă în intrare), mergând din spate în față.

LOG

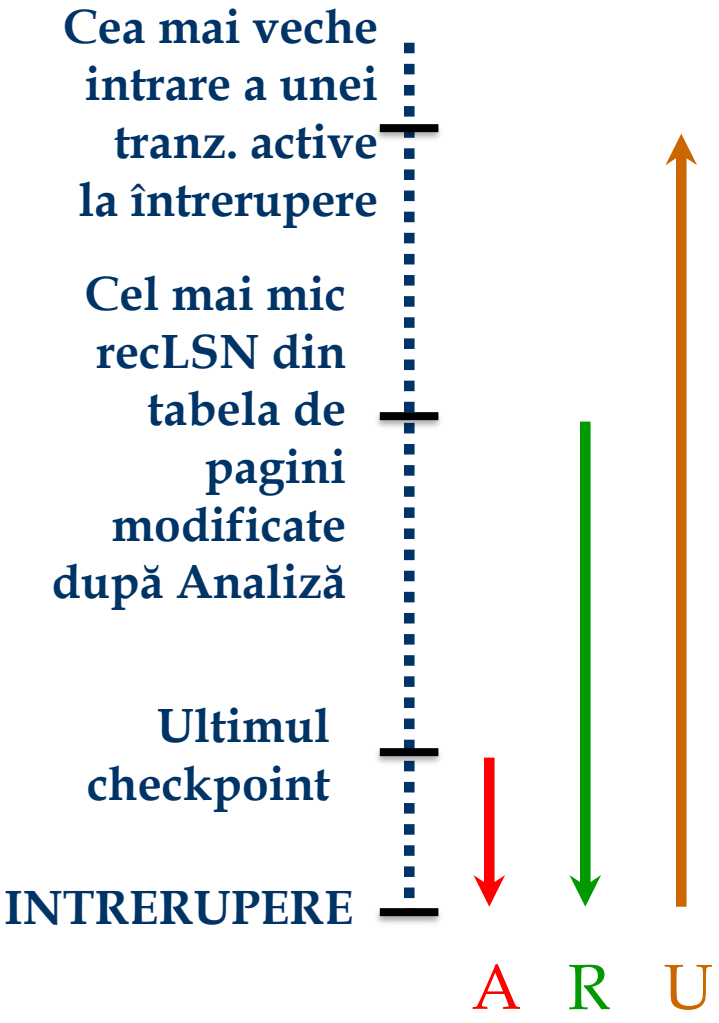

Se porneşte de la ultimul *checkpoint* (din *master record*).

Trei faze:

- Aflarea tranzacţiilor active sau cele comise de la ultimul checkpoint (Analiza).
- Reexecutarea tuturor acţiunilor tranz. comise (repetare istoric REDO)
- Anularea efectelor tranzacţiilor eşuate (UNDO).

Exemplu

Tabelă Tranz
- lastLSN
- stare

Tabelă Pagini Mod
- recLSN

flushedLSN

ToUndo

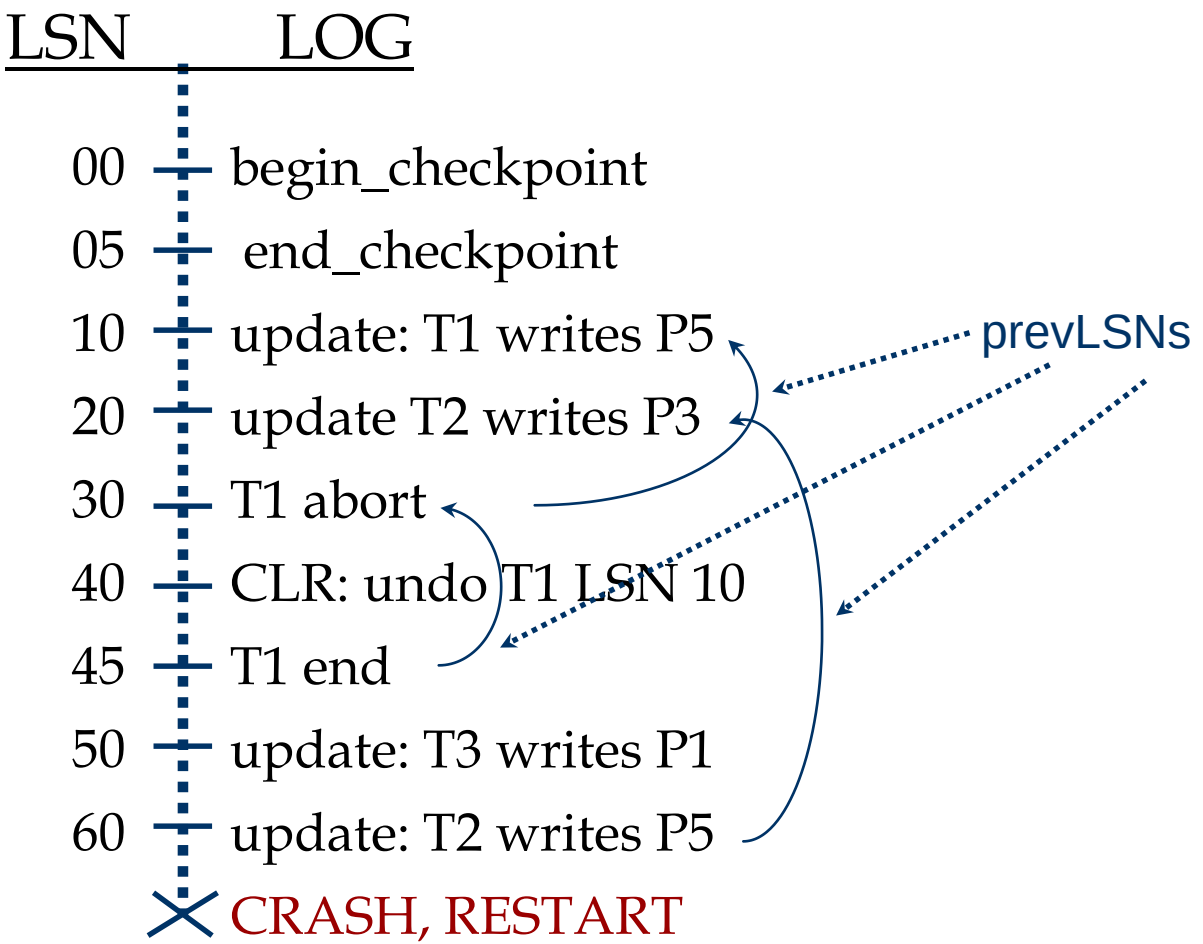

Exemplu

Tabelă Tranz
- lastLSN
- stare

Tabelă Pagini Mod
- recLSN

flushedLSN

ToUndo

LSN	LOG
00,05	begin_checkpoint, end_checkpoint
10	update: T1 writes P5
20	update T2 writes P3
30	T1 abort
40,45	CLR: undo T1 LSN 10, **T1 end**
50	update: T3 writes P1
60	update: T2 writes P5
	CRASH, RESTART
70	CLR: undo T2 LSN 60
80,85	CLR: undo T3 LSN 50, **T3 end**
	CRASH, RESTART
90,95	CLR: undo T2 LSN 20, **T2 end**

undonextLSN

Probleme suplimentare

- Pot să apară întreruperi în timpul recuperării bazei de date:
  - Se aplică *redo* şi *undo* o singură dată unei înregistrări, sau
  - *Redo* şi *undo* se construiesc ca acțiuni idempotente
- Limitarea duratei fazei de REDO:
  - Salvări asincrone de pagini.
- Limitarea duratei fazei de UNDO:
  - Evitarea tranzacțiilor ce durează mult.